دانشکده علوم ریاضی

فاز اول پروژه درس تحلیل داده

بررسی اثر فعالیت‌های انسانی بر حیات‌وحش ایران

نام و نام خانوادگی: زینب طباطبایی

شماره دانشجویی: ۴۰۳۱۰۰۵۱۳

درس: تحلیل داده

آبان ۱۴۰۵

فهرست مطالب

۱ مقدمه ۲

۲ منبع و معرفی داده‌ها ۲

۳ پاک‌سازی و آماده‌سازی داده‌ها ۲
۱.۳ نحوه برخورد با داده‌های ناقص ۳
۲.۳ ساختار نهایی داده‌ها ۳

۴ بررسی ساختار و کیفیت داده‌ها ۳
۱.۴ بررسی شناسه‌ها و مقادیر گمشده ۴
۲.۴ توزیع مشاهدات میان گروه‌های جانوری ۴
۳.۴ گونه‌های پرتکرار ۴

۵ بررسی زمانی مشاهدات ۵

۶ بررسی کاربران و کیفیت ثبت مشاهدات ۵

۷ بررسی تصاویر ۶
۱.۷ دسترس‌پذیری و ویژگی‌های فنی ۶
۲.۷ بررسی محتوای بصری ۶

۸ بررسی داده‌های تکراری ۷

۹ بررسی اطلاعات جغرافیایی ۷

۱۰ تعریف مسئله و مسیر مدل‌سازی ۸
۱.۱۰ تشخیص گونه جانوری از تصویر ۸
۲.۱۰ تشخیص وضعیت ظاهری حیوان ۸
۳.۱۰ تحلیل مکانی و زمانی مشاهدات ۸

۱۱ انتخاب مسئله اصلی و روش ارزیابی ۸
۱.۱۱ خط مبنا ۹
۲.۱۱ جلوگیری از نشت اطلاعات ۹

۱۲ محدودیت‌های داده و تحلیل ۹

۱۳ جمع‌بندی و برنامه مراحل بعدی ۱۰

۱ مقدمه

هدف این پروژه بررسی اثر فعالیت‌های انسانی بر حیات‌وحش ایران با استفاده از داده‌های واقعی و تصاویر ثبت‌شده از حیوانات است.

در این پروژه تلاش می‌شود نشانه‌های آسیب‌دیدگی، مرگ و سایر اثرات احتمالی فعالیت انسان بر حیوانات شناسایی شود و ارتباط آن‌ها با گونه‌های جانوری و موقعیت جغرافیایی بررسی شود.

در ادامه، با استفاده از روش‌های پردازش تصویر، بینایی ماشین و یادگیری ماشین، امکان شناسایی وضعیت حیوانات در تصاویر بررسی خواهد شد. همچنین اطلاعات مکانی و زمانی مشاهدات می‌تواند برای شناسایی مناطق نیازمند بررسی بیشتر و پیشنهاد اقدامات حفاظتی مورد استفاده قرار گیرد.

این گزارش به فاز نخست پروژه اختصاص دارد. در این مرحله، داده‌ها پاک‌سازی و ساختار آن‌ها بررسی شده و ویژگی‌ها، محدودیت‌ها و امکان استفاده از آن‌ها برای مراحل بعدی ارزیابی شده است.

۲ منبع و معرفی داده‌ها

داده‌های پروژه از وب‌سایت https://www.inaturalist.org/iNaturalist جمع‌آوری شده‌اند. این وب‌سایت بستری برای ثبت مشاهدات موجودات زنده توسط کاربران است و هر مشاهده می‌تواند شامل اطلاعات گونه، زمان، موقعیت جغرافیایی و تصاویر ثبت‌شده باشد.

محدوده داده‌های انتخاب‌شده به شرح زیر است:

- محدوده جغرافیایی: ایران
- بازه زمانی: ۲۰۱۶ تا ابتدای ۲۰۲۶
- گروه‌های جانوری: پرندگان، پستانداران، خزندگان و دوزیستان
- تعداد مشاهدات اولیه: حدود ۲۹ هزار مورد

داده‌ها از نوع مشاهدات میدانی ثبت‌شده توسط کاربران هستند و نمونه‌گیری تصادفی یا یکنواختی از تمام مناطق ایران محسوب نمی‌شوند.

۳ پاک‌سازی و آماده‌سازی داده‌ها

در مرحله نخست، داده‌های جمع‌آوری‌شده بررسی و پاک‌سازی شدند. هدف از این مرحله، آماده‌سازی مجموعه‌ای با ساختار یکسان و اطلاعات قابل استفاده برای تحلیل‌های بعدی بود.

مهم‌ترین اقدامات انجام‌شده عبارت‌اند از:

- بررسی مقادیر گمشده در ستون‌های مختلف
- بررسی شناسه‌های تکراری و یکتایی مشاهدات
- بررسی و اصلاح اطلاعات مربوط به زمان مشاهده
- بررسی اطلاعات موقعیت جغرافیایی
- تفکیک داده‌ها بر اساس چهار گروه جانوری
- بررسی تصاویر و شناسایی فایل‌های تکراری

۱.۳ نحوه برخورد با داده‌های ناقص

برای مقادیر گمشده در ستون محرمانگی موقعیت جغرافیایی، مقدار open در نظر گرفته شد.
در مشاهداتی که مختصات جغرافیایی نداشتند، با توجه به وضعیت محرمانگی موقعیت، دو روش متفاوت اعمال شد:

- در مواردی که موقعیت به‌صورت عمومی در دسترس نبود، مختصات مصنوعی در محدوده ایران تولید و با ستون location_is_synthetic مشخص شد.
- در مواردی که موقعیت عمومی بود اما مختصات ثبت نشده بود، رکورد حذف شد.

برای زمان‌های گمشده نیز از میانگین زمان مشاهده همان گونه استفاده شد. سایر مقادیر ناقص مطابق روش پاک‌سازی انتخاب‌شده حذف شدند.
نکته: مختصات مصنوعی نشان‌دهنده محل واقعی مشاهده نیستند و در تحلیل‌های جغرافیایی نباید به‌عنوان موقعیت واقعی حیوان در نظر گرفته شوند. همچنین زمان‌های تخمین‌زده‌شده، زمان واقعی ثبت مشاهده نیستند و باید در تحلیل‌های وابسته به زمان با احتیاط استفاده شوند.
پس از این مرحله، تعداد رکوردهای باقی‌مانده برابر با ۲۸,۹۲۶ مورد بود.

۲.۳ ساختار نهایی داده‌ها

داده‌های پاک‌سازی‌شده شامل ستون‌های زیر هستند:

	توضیح
id	شناسه عددی هر مشاهده
uuid	شناسه یکتای هر مشاهده
observed_on	تاریخ مشاهده حیوان
time_observed_at	زمان ثبت مشاهده
user_id	شناسه کاربر ثبت‌کننده
quality_grade	وضعیت کیفیت و اعتبار مشاهده
image_url	لینک تصویر مشاهده
latitude	عرض جغرافیایی
longitude	طول جغرافیایی
taxon_geoprivacy	وضعیت محرمانگی موقعیت جغرافیایی
common_name	نام رایج حیوان
taxon_class_name	رده جانوری
taxon_order_name	راسته جانوری
taxon_family_name	خانواده جانوری
location_is_synthetic	مشخص‌کننده مصنوعی بودن مختصات
dataset_class	گروه جانوری هر رکورد

جدول ۱: ستون‌های مجموعه داده پاک‌سازی‌شده

داده‌ها در چهار فایل جداگانه برای پرندگان، پستانداران، خزندگان و دوزیستان ذخیره شده‌اند.

۴ بررسی ساختار و کیفیت داده‌ها

پس از پاک‌سازی، ساختار مجموعه داده از نظر تعداد رکوردها، مقادیر گمشده، شناسه‌ها و توزیع مشاهدات بررسی شد.

۱.۴ بررسی شناسه‌ها و مقادیر گمشده

در مجموعه داده نهایی، ۲۸,۹۲۶ رکورد و ۱۷ ستون وجود دارد. پس از پاک‌سازی، هیچ مقدار گمشده‌ای در ستون‌های بررسی‌شده باقی نمانده است.

همچنین شناسه‌های id و uuid در تمام رکوردها یکتا هستند.

ستون user_id دارای ۶۲۷ مقدار یکتا است. تکرار این شناسه‌ها طبیعی است؛ زیرا هر کاربر می‌تواند تعداد زیادی مشاهده ثبت کند.

۲.۴ توزیع مشاهدات میان گروه‌های جانوری

توزیع مشاهدات در چهار گروه جانوری به شکل زیر است:

گروه جانوری	تعداد	درصد
پرندگان	۱۹,۵۳۶	۶۷٫۵۴٪
خزندگان	۴,۳۷۸	۱۵٫۱۴٪
پستانداران	۳,۳۵۹	۱۱٫۶۱٪
دوزیستان	۱,۶۵۳	۵٫۷۱٪
مجموع	۲۸,۹۲۶	۱۰۰٪

جدول ۲: توزیع مشاهدات بر اساس گروه جانوری

همان‌طور که مشخص است، پرندگان بیشترین سهم از داده‌ها را دارند و تعداد مشاهدات دوزیستان به‌مراتب کمتر است.

این عدم توازن در مراحل بعدی مدل‌سازی اهمیت دارد؛ زیرا مدلی که صرفاً بر اساس فراوانی نمونه‌ها آموزش داده شود، ممکن است در تشخیص گروه‌های کم‌نمونه عملکرد ضعیف‌تری داشته باشد.

۳.۴ گونه‌های پرتکرار

بررسی نام‌های رایج نشان می‌دهد که گونه‌هایی مانند گربه خانگی، گنجشک خانگی و سگ خانگی بیشترین تعداد مشاهده را دارند.

نام رایج	تعداد مشاهده
Cat Domestic	۹۰۸
Sparrow House	۶۱۱
Dog Domestic	۵۹۹
Bulbul White-eared	۴۸۴
Dove Laughing	۴۶۹
Toad Variable	۴۲۹
Pigeon Feral	۴۱۲
Crow Hooded	۴۰۵
Wagtail White	۳۸۵
Frog Marsh	۳۶۱

جدول ۳: ده گونه پرتکرار در مجموعه داده

تفاوت فراوانی گونه‌ها نشان می‌دهد که مسئله تشخیص گونه با چالش عدم توازن داده روبه‌رو است. تعداد زیادی از گونه‌ها نمونه‌های اندکی دارند و این موضوع می‌تواند آموزش مدل‌های تشخیص گونه را دشوار کند.

۵ بررسی زمانی مشاهدات

تعداد مشاهدات ثبت‌شده در سال‌های مختلف بررسی شد:

سال	تعداد مشاهدات
۲۰۱۶	۱,۱۲۵
۲۰۱۷	۱,۸۳۷
۲۰۱۸	۱,۱۲۹
۲۰۱۹	۲,۰۰۸
۲۰۲۰	۹۷۳
۲۰۲۱	۱,۹۷۳
۲۰۲۲	۲,۷۲۸
۲۰۲۳	۴,۲۸۳
۲۰۲۴	۵,۰۷۳
۲۰۲۵	۷,۷۴۶
۲۰۲۶	۵۱

جدول ۴: تعداد مشاهدات ثبت‌شده در هر سال

تعداد مشاهدات در سال‌های اخیر افزایش قابل توجهی داشته است. با این حال، افزایش تعداد مشاهدات لزوماً به معنای افزایش جمعیت جانوران یا کاهش و افزایش آسیب‌های واردشده به آن‌ها نیست؛ زیرا میزان فعالیت کاربران و پوشش داده‌ها نیز در طول زمان تغییر می‌کند.
همچنین داده‌های سال ۲۰۲۶ فقط بخش ابتدایی این سال را پوشش می‌دهند و نباید با سال‌های کامل مقایسه شوند.

۶ بررسی کاربران و کیفیت ثبت مشاهدات

در مجموعه داده ۶۲۷ کاربر مختلف وجود دارد. تعداد مشاهدات ثبت‌شده توسط کاربران توزیع یکنواختی ندارد.
میانگین تعداد مشاهدات هر کاربر حدود ۴۶ مورد و میانه آن ۲ مورد است. همچنین بیشترین تعداد مشاهدات ثبت‌شده توسط یک کاربر برابر با ۴,۰۹۱ مورد است.
این تفاوت نشان می‌دهد که بخش قابل توجهی از داده‌ها ممکن است تحت تأثیر فعالیت تعداد محدودی از کاربران باشد.
از طرف دیگر، ستون quality_grade وضعیت بررسی و اعتبار مشاهده را نشان می‌دهد. درصد مشاهدات دارای وضعیت Research Grade در گروه‌های مختلف به شرح زیر است:

گروه جانوری	Grade Research	ID Needs
دوزیستان	۸۷٫۲۴٪	۱۲٫۷۶٪
پرندگان	۹۰٫۴۵٪	۹٫۵۵٪
پستانداران	۸۹٫۳۷٪	۱۰٫۶۳٪
خزندگان	۹۰٫۶۶٪	۹٫۳۴٪

جدول ۵: درصد وضعیت‌های مختلف کیفیت مشاهدات

وضعیت Research Grade به معنای طی شدن فرایند بررسی و تأیید در iNaturalist است، اما به‌تنهایی تضمین‌کننده صحت قطعی تمام اطلاعات گونه‌شناسی نیست.

۷ بررسی تصاویر

از آنجا که بخش مهمی از پروژه بر پردازش تصویر و تشخیص وضعیت حیوانات متکی است، تصاویر از نظر دسترس‌پذیری، ویژگی‌های فنی و محتوای بصری بررسی شدند.

۱.۷ دسترس‌پذیری و ویژگی‌های فنی

تمام ۲۸,۹۲۶ تصویر دانلودشده با موفقیت باز شدند و در بررسی اولیه، تصویر ناقص یا غیرقابل‌خواندن مشاهده نشد.
میانگین ابعاد تصاویر در گروه‌های مختلف به‌صورت تقریبی در بازه‌های زیر قرار دارد:

- میانگین عرض تصاویر: حدود ۴۳۵ تا ۴۷۱ پیکسل
- میانگین ارتفاع تصاویر: حدود ۳۹۷ تا ۴۳۹ پیکسل

همچنین روشنایی تصاویر بررسی شد. به‌طور میانگین، تصاویر پرندگان روشنایی بیشتری داشتند و تصاویر دوزیستان از روشنایی کمتری برخوردار بودند.
البته روشنایی و ابعاد تصویر به‌تنهایی معیار کافی برای تعیین کیفیت بصری یا مناسب بودن تصویر برای آموزش مدل نیستند.

۲.۷ بررسی محتوای بصری

برای بررسی دقیق‌تر محتوای تصاویر، از هر گروه جانوری به‌صورت تصادفی ۱۰۰ تصویر انتخاب و به‌صورت دستی مشاهده شد.
نتایج این بررسی به شرح زیر است:

- پرندگان: تنوع تصویری نسبتاً زیادی مشاهده شد. تصاویر شامل محیط‌هایی مانند آسمان، زمین و دشت بودند و در بیشتر نمونه‌های بررسی‌شده وضعیت تصویر مناسب بود.
- پستانداران: در نمونه‌های بررسی‌شده، علاوه بر تصاویر حیوانات زنده، مواردی از حیوانات مرده و لاشه نیز وجود داشت. همچنین تصاویری از پستانداران دریایی و مواردی شامل چند حیوان در یک تصویر مشاهده شد.
- خزندگان: در بخشی از تصاویر دست انسان یا نگه‌داشتن حیوان توسط انسان دیده می‌شد. همچنین نمونه‌هایی از حیوانات مرده یا آسیب‌دیده وجود داشت.

- دوزیستان: بیشتر تصاویر بررسی‌شده مربوط به قورباغه‌ها بودند. در برخی نمونه‌ها، حیوان نسبت به کل کادر تصویر اندازه کوچکی داشت.

این بررسی نشان می‌دهد که مجموعه تصاویر از نظر زاویه عکاسی، اندازه حیوان در تصویر، پس‌زمینه و وضعیت ظاهری تنوع زیادی دارد.
همچنین وجود تصاویر حیوانات مرده یا آسیب‌دیده می‌تواند برای هدف اصلی پروژه مفید باشد؛ اما تعداد و نسبت واقعی این موارد هنوز مشخص نیست و برای تعیین آن به بررسی و برچسب‌گذاری دقیق تصاویر نیاز است.
لازم به ذکر است که این نتایج فقط مربوط به نمونه تصادفی ۱۰۰ تصویری هر گروه است و نمی‌توان آن را به تمام تصاویر مجموعه داده تعمیم داد.

۸ بررسی داده‌های تکراری

برای شناسایی تصاویر کاملاً یکسان، از روش هش‌گذاری فایل‌ها استفاده شد. در این روش، برای هر تصویر یک مقدار هش محاسبه می‌شود و تصاویر دارای هش یکسان به‌عنوان فایل‌های تکراری شناسایی می‌شوند.
نتایج بررسی به شرح زیر است:

- تعداد تصاویر بررسی‌شده: ۲۸,۹۲۶
- تعداد فایل‌های متعلق به گروه‌های تکراری: ۲۰۴
- تعداد گروه‌های تکراری: ۹۷
- تعداد گروه‌های دارای تکرار بین چند رده جانوری: ۵

تکرار بین چند رده جانوری اهمیت ویژه‌ای دارد؛ زیرا ممکن است یک تصویر در چند مشاهده با برچسب‌های متفاوت ثبت شده باشد. این موارد باید پیش از آموزش مدل با دقت بررسی شوند.
وجود تصاویر یکسان در مجموعه آموزش و آزمون می‌تواند باعث نشت اطلاعات شود و ارزیابی عملکرد مدل را غیرواقعی کند. به همین دلیل، شناسایی و مدیریت این تصاویر در آماده‌سازی داده‌های مدل‌سازی ضروری است.

۹ بررسی اطلاعات جغرافیایی

تمام رکوردهای مجموعه داده دارای مقادیر مختصات جغرافیایی هستند؛ با این حال، بخشی از مختصات به‌صورت مصنوعی تولید شده‌اند.
بنابراین، در تحلیل‌های مکانی باید فقط از مختصات واقعی استفاده شود و رکوردهای دارای مقدار location_is_synthetic=True کنار گذاشته شوند.
از اطلاعات مکانی می‌توان برای بررسی پراکندگی مشاهدات گونه‌های مختلف و شناسایی مناطق دارای تمرکز بالای گزارش‌های مربوط به حیوانات آسیب‌دیده استفاده کرد.
در مراحل بعدی، امکان بررسی ارتباط این مناطق با جاده‌ها، مناطق شهری، زیرساخت‌های انسانی و مناطق حفاظت‌شده نیز وجود دارد.
با این حال، تعداد مشاهدات ثبت‌شده در یک منطقه لزوماً نشان‌دهنده تعداد واقعی حیوانات یا میزان آسیب‌دیدگی آن‌ها نیست. تراکم کاربران و تفاوت میزان دسترسی به مناطق مختلف نیز بر تعداد مشاهدات تأثیر می‌گذارد.

۱۰ تعریف مسئله و مسیر مدل‌سازی

با توجه به هدف پروژه و ویژگی‌های مجموعه داده، چند مسئله اصلی برای مراحل بعدی در نظر گرفته شده است.

۱.۱۰ تشخیص گونه جانوری از تصویر

هدف این بخش، شناسایی گونه حیوان از روی تصویر است. بر خلاف دسته‌بندی اولیه داده‌ها در چهار گروه جانوری، در این مرحله تلاش می‌شود تشخیص در سطح گونه انجام شود.
ستون common_name می‌تواند به‌عنوان برچسب اولیه برای آموزش مدل استفاده شود. البته پیش از آموزش، لازم است کیفیت این برچسب‌ها و تعداد نمونه‌های هر گونه بررسی شود.
این مسئله را می‌توان به‌عنوان یک مسئله طبقه‌بندی تصویر در نظر گرفت.

۲.۱۰ تشخیص وضعیت ظاهری حیوان

هدف این بخش، تفکیک تصاویر بر اساس وضعیت قابل مشاهده حیوان است. دسته‌بندی اولیه پیشنهادی شامل موارد زیر است:

- حیوان زنده و بدون آسیب ظاهری مشخص
- حیوان دارای آسیب ظاهری
- حیوان مرده
- وضعیت نامشخص یا غیرقابل تشخیص

در حال حاضر، مجموعه داده برچسب مستقیمی برای این دسته‌بندی ندارد. بنابراین، لازم است بخشی از تصاویر به‌صورت دستی بررسی و برچسب‌گذاری شوند.
همچنین تشخیص آسیب ظاهری از روی تصویر به معنای تشخیص قطعی وضعیت سلامت حیوان نیست؛ زیرا همه آسیب‌ها در تصویر قابل مشاهده نیستند.

۳.۱۰ تحلیل مکانی و زمانی مشاهدات

در این بخش از نام گونه‌ها، تاریخ و مختصات واقعی برای بررسی پراکندگی مشاهدات استفاده می‌شود.
پس از مشخص شدن تصاویر آسیب‌دیده، می‌توان مناطق دارای تمرکز بالای این مشاهدات را شناسایی کرد و ارتباط احتمالی آن‌ها را با عوامل انسانی بررسی کرد.
این بخش علاوه بر تحلیل آماری، می‌تواند زمینه‌ای برای استفاده از مدل‌های مکانی و ترکیب اطلاعات تصویر و موقعیت جغرافیایی فراهم کند.

۱۱ انتخاب مسئله اصلی و روش ارزیابی

سه مسئله مطرح‌شده از نظر نوع داده و روش اجرا تفاوت دارند. تشخیص گونه به برچسب‌های موجود و تصاویر وابسته است؛ تشخیص آسیب به برچسب‌گذاری جدید نیاز دارد؛ و تحلیل مکانی و زمانی بیشتر بر اطلاعات توصیفی و جغرافیایی متکی است.
برای شروع بخش یادگیری ماشین، تشخیص گونه جانوری از تصویر به‌عنوان مسئله اولیه مناسب‌تر است؛ زیرا تصاویر و برچسب‌های اولیه آن در مجموعه داده وجود دارند.
در ادامه، پس از آماده‌سازی برچسب‌های وضعیت ظاهری، مسئله تشخیص آسیب نیز قابل بررسی خواهد بود. تحلیل مکانی و زمانی می‌تواند به‌عنوان بخش مکمل برای تفسیر نتایج استفاده شود.

۱.۱۱ خط مبنا

برای ارزیابی اولیه مدل تشخیص گونه، می‌توان یک مدل ساده در نظر گرفت که در تمام موارد پرتکرارترین گونه مجموعه آموزش را پیش‌بینی کند.

این مدل خط مبنای ساده‌ای برای مقایسه عملکرد مدل‌های پیچیده‌تر فراهم می‌کند.

با توجه به نامتوازن بودن تعداد نمونه‌های گونه‌ها، استفاده از معیار دقت به‌تنهایی کافی نیست. در مراحل بعدی، معیارهایی مانند Precision، Recall، F1-score و به‌ویژه Macro F1 نیز بررسی خواهند شد.

۲.۱۱ جلوگیری از نشت اطلاعات

در طراحی مجموعه‌های آموزش و آزمون باید از ورود اطلاعاتی که پاسخ مسئله را مستقیماً یا غیرمستقیم مشخص می‌کنند جلوگیری شود.

برای مسئله تشخیص گونه از تصویر، ستون‌هایی مانند common_name، taxon_class_name، taxon_order_name، taxon_family_name و dataset_class نباید به‌عنوان ورودی مدل تصویری استفاده شوند؛ زیرا برچسب هدف یا اطلاعاتی بسیار نزدیک به آن را در اختیار مدل قرار می‌دهند.

همچنین باید از قرار گرفتن تصاویر تکراری یا بسیار مشابه در مجموعه آموزش و آزمون جلوگیری شود.

از طرف دیگر، ممکن است مدل به‌جای ویژگی‌های خود حیوان، از پس‌زمینه تصویر، سبک عکاسی کاربران یا اطلاعات مکانی برای پیش‌بینی استفاده کند. برای بررسی این موضوع، می‌توان عملکرد مدل را در شرایطی مانند جداسازی کاربران یا مناطق جغرافیایی مقایسه کرد.

۱۲ محدودیت‌های داده و تحلیل

مهم‌ترین محدودیت‌های شناسایی‌شده در این مرحله عبارت‌اند از:

- تعداد مشاهدات ثبت‌شده لزوماً نشان‌دهنده تعداد واقعی حیوانات یا میزان مرگ‌ومیر نیست.
- پوشش جغرافیایی داده‌ها یکنواخت نیست و برخی مناطق مشاهدات بیشتری دارند.
- تعداد مشاهدات گونه‌های مختلف بسیار متفاوت است.
- بخشی از مختصات به‌صورت مصنوعی تولید شده‌اند و برای تحلیل جغرافیایی معتبر نیستند.
- بخشی از زمان‌های مشاهده با استفاده از میانگین تخمین زده شده‌اند.
- کیفیت تصاویر، زاویه عکاسی، فاصله از حیوان و شرایط محیطی متفاوت است.
- در حال حاضر برچسب مشخصی برای وضعیت آسیب‌دیدگی یا مرگ حیوانات وجود ندارد.
- مشاهده لاشه در کنار جاده به‌تنهایی اثبات‌کننده تصادف جاده‌ای نیست.
- مدل ممکن است به نشانه‌هایی مانند پس‌زمینه جاده، خون یا حالت قرارگیری بدن حیوان وابسته شود، نه خود مفهوم آسیب.
- تفاوت میزان فعالیت کاربران می‌تواند نتایج تحلیل زمانی و مکانی را تحت تأثیر قرار دهد.

برای بررسی دقیق‌تر اثر فعالیت‌های انسانی، در مراحل بعدی به داده‌های تکمیلی مانند موقعیت جاده‌ها، تراکم مناطق شهری، مناطق حفاظت‌شده، حجم ترافیک و اطلاعات مربوط به اقدامات حفاظتی نیاز خواهد بود.

۱۳ جمع‌بندی و برنامه مراحل بعدی

در فاز نخست، داده‌های جمع‌آوری‌شده از iNaturalist پاک‌سازی و از نظر ساختار، کیفیت، توزیع گونه‌ها، اطلاعات زمانی و مکانی و ویژگی‌های تصاویر بررسی شدند.
مجموعه داده نهایی شامل ۲۸,۹۲۶ مشاهده از چهار گروه جانوری است. بررسی‌ها نشان داد که داده‌ها از نظر تعداد نمونه‌ها، کیفیت تصاویر، فراوانی گونه‌ها و میزان فعالیت کاربران توزیع یکنواختی ندارند.
همچنین وجود تصاویر حیوانات مرده و آسیب‌دیده در نمونه‌های بررسی‌شده نشان می‌دهد که امکان مطالعه وضعیت ظاهری حیوانات در این مجموعه وجود دارد؛ اما برای انجام تحلیل دقیق، باید تصاویر به‌صورت هدفمند برچسب‌گذاری شوند.
برنامه مراحل بعدی پروژه به شرح زیر است:

۱. تکمیل بررسی تصاویر و شناسایی تصاویر نامرتبط یا نامناسب
۲. بررسی و آماده‌سازی برچسب‌های گونه‌ها برای آموزش مدل
۳. ایجاد یک مجموعه برچسب‌گذاری‌شده برای وضعیت ظاهری حیوانات
۴. آموزش و ارزیابی مدل‌های اولیه تشخیص گونه
۵. بررسی امکان تشخیص آسیب‌دیدگی با استفاده از روش‌های بینایی ماشین
۶. تحلیل پراکندگی مکانی و زمانی مشاهدات و بررسی ارتباط احتمالی آن با عوامل انسانی
۷. ترکیب اطلاعات تصویری و جغرافیایی در صورت کافی بودن داده‌ها

هدف نهایی پروژه، تبدیل داده‌ها و تصاویر پراکنده به اطلاعاتی کاربردی برای شناخت تهدیدهای حیات‌وحش ایران و کمک به تصمیم‌گیری‌های حفاظتی است.